

Entrega 1 - Introducción a la Ciencia de Datos

Grupo 8: Facundo Morini, Cecilia Waksman

2026-05-25

Datos: *All the News 2.1 – Component One*

30.213 observaciones.

Variables:

- ▶ `idx` y `article_idx`: identificadores
- ▶ `date`, `year`, `month` y `day`: fecha de publicación. Corresponden al período 2016-2020
- ▶ `publication`: medio de prensa. 26 medios
- ▶ `title`: título de la noticia
- ▶ `article`: cuerpo del artículo
- ▶ `author`: autor del artículo
- ▶ `url`. dirección URL
- ▶ `section`: sección temática

Tabla 1: Resumen de las variables disponibles en la base de datos.

Variable	Tipo	Valores únicos	No faltantes	% faltantes
idx	int64	30213	30213	0.00
article_idx	int64	30213	30213	0.00
date	datetime64[ns]	9246	30213	0.00
year	int64	5	30213	0.00
month	float64	12	30213	0.00
day	int64	31	30213	0.00
author	string	7022	18808	37.75
title	string	29888	30213	0.00
article	string	28926	29037	3.89
url	string	30072	30072	0.47
section	string	707	19981	33.87
publication	string	26	30072	0.47




Figura 1: Diez medios con mayor cantidad de artículos en la base de datos.

5 medios con más artículos




Figura 2: Cantidad mensual de artículos publicados por los cinco medios principales.

Limpieza y Normalización del Texto

Se sustituyen por espacios:

- ▶ signos de puntuación
- ▶ encabezados o fragmentos iniciales que aparecían antes del primer salto de línea
- ▶ símbolos especiales
- ▶ espacios dobles
- ▶ números
- ▶ fragmentos con caracteres no alfabéticos

Texto se transforma a minúsculas.

Tabla 2: Ejemplo de texto original y texto procesado.

article	CleanText
Feb 2 (Reuters) - Teva Pharmac... The head of the Centers for Me... Benchmark, the venture capital... (Updates with new first paragr... TORONTO, Dec 4 (Reuters) - Ban...	feb reuters teva pharmaceutica... the head of the centers for me... benchmark the venture capital ... updates with new first paragra... toronto dec reuters bank of mo...

Menciones al medio




Figura 3: Porcentaje de artículos con pistas directas del medio de prensa.

Conteo de palabras







Figura 4: Nube de palabras de los artículos.

Es necesario filtrar *stopwords*.

[illegible][illegible][illegible][illegible]

Análisis de correspondencias




Figura 6: Nube de palabras de los artículos por medio de prensa.

Medio con mayor cantidad de palabras




Figura 7: Cantidad total y promedio de palabras por artículo según medio de prensa.

Matriz de menciones entre medios




Figura 8: Cantidad de menciones cruzadas entre medios de prensa por nombre o URL.

Grafo de menciones cruzadas

Grafo dirigido de menciones entre medios




Figura 9: Grafo dirigido de menciones cruzadas entre medios de prensa. Se excluyen automenciones.

Preguntas propuestas

- ▶ Es posible distinguir el medio de prensa únicamente por su vocabulario? Y si se toma en cuenta también la estructura y estilo de escritura del artículo?
- ▶ Se pueden asociar ciertas temáticas a determinados autores?
- ▶ El título del artículo alcanza para predecir el medio de prensa?
- ▶ Cómo cambia la distribución temática de los artículos a lo largo del tiempo para cada medio de prensa?