

Entrega 1 - Introducción a la Ciencia de Datos

Grupo 8: Facundo Morini, Cecilia Waksman

2026-05-27

Datos y objetivo

Datos utilizados

- ▶ Dataset: *All the News 2.1 – Component One*.
- ▶ 30.213 artículos periodísticos.
- ▶ Período: 2016–2020.
- ▶ 26 medios de prensa.
- ▶ Variables centrales: fecha, medio, título, cuerpo del artículo, autor, URL y sección.

Objetivo

Realizar un análisis exploratorio de artículos periodísticos de distintos medios, con el fin de:

- ▶ estudiar la estructura y calidad del dataset;
- ▶ analizar la distribución de artículos entre medios;
- ▶ limpiar y normalizar el texto para estudiar patrones de vocabulario;
- ▶ comparar los cinco medios principales mediante visualizaciones descriptivas.

Medios seleccionados y cobertura temporal




Figura 1: Cantidad mensual de artículos publicados por los cinco medios principales.

Los cinco medios reúnen **18.771 artículos**, equivalente al **62,42 %** del total.

Limpieza del texto y pistas directas

Normalización aplicada

- ▶ Minúsculas.
- ▶ Eliminación de encabezados iniciales.
- ▶ Sustitución de puntuación, símbolos y números.
- ▶ Normalización de espacios.
- ▶ Filtrado posterior de *stopwords*.







Figura 2: Porcentaje de artículos con pistas directas del medio.

Vocabulario por medio



Correspondencias: asociación medio-palabra




Figura 4: Análisis de correspondencias entre medios y palabras frecuentes.

Menciones cruzadas y cierre




Figura 5: Menciones cruzadas entre medios por nombre o URL.

Preguntas propuestas

- ▶ Es posible distinguir el medio de prensa únicamente por su vocabulario? Y si se toma en cuenta también la estructura y estilo de escritura del artículo?
- ▶ Se pueden asociar ciertas temáticas a determinados autores?
- ▶ El título del artículo alcanza para predecir el medio de prensa?
- ▶ Cómo cambia la distribución temática de los artículos a lo largo del tiempo para cada medio de prensa?