

Entrega 2 - Introducción a la Ciencia de Datos

Grupo 8: Facundo Morini, Cecilia Waksman

En este trabajo se busca construir un modelo de clasificación de texto capaz de predecir a qué medio de prensa pertenece un artículo periodístico a partir únicamente de su contenido textual. Para esto se utiliza un subconjunto del dataset *All the News 2.1 – Component One*, que reúne artículos de distintos medios junto con los metadatos asociados a cada publicación. Todo el material y código utilizado para llevar a cabo este trabajo, así como también otros análisis previos, se pueden encontrar en el siguiente [link](#) al repositorio de Github.

El análisis exploratorio que se realizó previamente sobre estos mismos datos ya había dejado algunas señales útiles para esta etapa. La primera es el fuerte desbalance en la cantidad de artículos entre medios (Figura 1): **Reuters** concentra una porción muy superior al resto, algo que conviene tener presente tanto al entrenar los modelos como, sobre todo, al interpretar sus métricas. La segunda es que los propios artículos suelen incluir pistas directas de su origen, como menciones al nombre del medio, direcciones web o firmas editoriales, que de no removerse podrían facilitar la tarea de forma artificial. La tercera es que, aunque los medios comparten temáticas transversales como la política estadounidense, muestran perfiles de vocabulario diferenciados. Esto último queda resumido en el análisis de correspondencias entre medios y términos frecuentes (Figura 2): **Reuters** y **CNBC** aparecen próximos entre sí y ligados a un lenguaje económico e internacional, mientras que **The New York Times** se inclina hacia la política y hacia temas más cercanos a la vida cotidiana y la cultura. Estas diferencias sugieren, desde un principio, que habrá medios más fáciles de distinguir que otros.

En este caso primero se traduce el texto a una representación numérica con la que un modelo pueda operar, explorando técnicas como *bag of words* y *TF-IDF*, y observando mediante una reducción de dimensionalidad hasta qué punto los medios resultan separables. Luego se entrena y evalúa el rendimiento de modelos *Multinomial Naive Bayes*, midiendo su desempeño con métricas de clasificación. Los resultados obtenidos se comparan con los que se obtienen mediante una *Regresión Logística Multinomial*. Por último, se evalúa el efecto del desbalance de clases y se discuten otras técnicas alternativas de extracción de features.

Dataset y representación numérica de texto

1. Preparación de los datos

Para esta tarea el análisis se restringe a los tres medios con mayor cantidad de artículos de la base, ya identificados: **Reuters**, **The New York Times** y **CNBC** (Figura 1). Una vez descartados los artículos sin cuerpo de texto, estos tres medios reúnen 14.660 artículos, sobre los que se construye el conjunto de trabajo.




Figura 1: Diez medios con mayor cantidad de artículos en la base.




Figura 2: Análisis de correspondencias entre los cinco medios principales y las palabras más frecuentes.

Sobre el cuerpo de cada artículo (variable `article`) se aplica una misma función, de modo de homogeneizar el texto antes de convertirlo en una representación numérica. Esta función elimina el encabezado que precede al primer salto de línea, convierte el texto a minúsculas, reemplaza los signos de puntuación y los saltos de línea por espacios, descarta las palabras que contienen caracteres no alfabéticos (restos de enlaces, números o códigos) y, finalmente, colapsa los espacios múltiples en uno solo.

A partir de este conjunto se separa un 30 % de los artículos para conformar el conjunto de test, reservando el 70 % restante para el entrenamiento. Dado el fuerte desbalance entre medios: **Reuters** concentra cerca del 63 % de los artículos, frente a un 19 % de **The New York Times** y un 18 % de **CNBC**, la partición se realiza mediante **muestreo estratificado**. De esta forma se garantiza que cada medio conserve aproximadamente la misma proporción en ambos subconjuntos, evitando que, por azar, alguno de los medios minoritarios quede sub o sobre-representado en el conjunto de test. Como resultado, el conjunto de entrenamiento queda conformado por 10.262 artículos y el de test por 4.398.

Para verificar que la estratificación efectivamente preservó el balance original, en la Figura 3 se compara la proporción de artículos de cada medio en el conjunto total y en los conjuntos de entrenamiento y test.

Las proporciones resultan prácticamente idénticas en los tres conjuntos: las diferencias entre train y test no superan la centésima de punto porcentual para ningún medio. De todas formas, la figura vuelve a dejar en evidencia el marcado desbalance entre clases, con **Reuters** representando casi dos tercios del total. Este desbalance no se corrige, sino que se mantiene de forma

deliberada para trabajar sobre los datos tal como se presentan, pero conviene tenerlo presente de cara a la evaluación de los modelos, ya que condiciona la interpretación de métricas como la *accuracy*, según se discutirá posteriormente.




Figura 3: Proporción de artículos de cada medio en el conjunto total, de entrenamiento y de test.

2. Representación Bag of Words

La técnica de *bag of words* (BOW) traduce cada artículo a un vector de conteos de palabras. Concretamente, se construye una matriz en la que cada fila corresponde a un artículo y cada columna a una de las palabras distintas presentes en el conjunto de entrenamiento; el valor de cada celda es la cantidad de veces que esa palabra aparece en ese artículo. El nombre de la técnica refleja que se descarta el orden de las palabras: solo importa cuántas veces aparece cada una, y no su posición ni el contexto en que se encuentra.

Aplicada sobre el conjunto de entrenamiento, esta transformación produce una matriz de dimensiones (10262, 82287): 10.262 artículos por las 82.287 palabras distintas que conforman el vocabulario.

A modo de ejemplo, en el Cuadro 1 se muestran los conteos de seis palabras del primer artículo, para los cinco primeros artículos del conjunto de entrenamiento. Se eligieron columnas con al menos un valor distinto de cero.

Tabla 1: Ejemplo de representación Bag of Words.

los	angeles	reuters	star	wars	actress
4	4	1	4	3	3
0	0	1	0	0	0
0	0	1	0	0	0
0	0	0	0	0	0
0	0	0	0	0	0

El ejemplo ya anticipa una característica central de esta representación: la enorme mayoría de las celdas valen cero. Cada artículo utiliza apenas una pequeña fracción del vocabulario total; en este subconjunto, el promedio de palabras por artículo es de aproximadamente $424 \ll 82287$, muy por debajo del número de columnas. Incluso el artículo más extenso, con $12069 < 82287$ palabras, está lejos de cubrir el vocabulario completo, de modo que la fila que le corresponde sigue estando dominada por ceros. Por este motivo se dice que la matriz es dispersa.

Por último, vale señalar que esta representación es generalizable: en lugar de contar palabras sueltas, puede contarse la frecuencia de cada secuencia de n palabras consecutivas un **n-grama**, es decir, una secuencia de n elementos contiguos, en lo que se conoce como *bag of n-grams*. Vista así, BOW no es más que el caso particular con $n = 1$.

3. Representación TF-IDF

La representación *Term Frequency – Inverse Document Frequency* (TF-IDF) aborda una limitación de los conteos absolutos de BOW: dependen del largo del texto, ya que un artículo más extenso tenderá a repetir más veces cada palabra. El primer componente, *Term Frequency* (TF), corrige esto reemplazando el conteo por una frecuencia relativa al largo del texto:

$$TF_{t,p} = \frac{\text{conteo de la palabra } p \text{ en el texto } t}{\text{conteo total de palabras en el texto } t}$$

El segundo componente, *Inverse Document Frequency* (IDF), pondera cada palabra según qué tan extendida está en el conjunto de textos. Se define como el logaritmo del cociente entre la cantidad total de textos y la cantidad de textos que contienen la palabra:

$$IDF_p = \log\left(\frac{\text{cantidad total de textos}}{\text{cantidad de textos que contienen la palabra } p}\right)$$

De esta forma, las palabras que aparecen en muchos textos y que, por lo tanto, son poco distintivas, como *the*, *and* o *a* reciben un peso bajo, mientras que las que aparecen en pocos textos, presumiblemente más informativas del contenido, reciben un peso alto.

La representación final se obtiene multiplicando ambos componentes:

$$TF-IDF_{t,p} = TF_{t,p} \times IDF_p$$

Reutilizando las mismas palabras del ejemplo anterior, el Cuadro 2 muestra ahora su representación TF-IDF.

Tabla 2: Ejemplo de representación TF-IDF.

los	angeles	reuters	star	wars	actress
0.1289	0.1304	0.0108	0.1272	0.1223	0.1248
0.0000	0.0000	0.0251	0.0000	0.0000	0.0000
0.0000	0.0000	0.0096	0.0000	0.0000	0.0000
0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
0.0000	0.0000	0.0000	0.0000	0.0000	0.0000

En el primer artículo, la mayoría de las palabras del ejemplo toman valores parecidos, en torno a 0.12 – 0.13. La excepción es **Reuters**, con un valor mucho menor (0.01), y esto se explica por los dos componentes a la vez. Por un lado, su *TF* es bajo: en ese artículo **Reuters** aparece una sola vez, frente a las cuatro apariciones de palabras como **los** o **star**. Por otro, y sobre todo, su *IDF* también es bajo: **Reuters** figura en una gran cantidad de artículos, algo ya previamente visto, donde **Reuters** resultó ser el medio con más artículos y el que más se menciona a sí mismo. Al estar tan extendida, la palabra aporta poca información para distinguir un artículo de otro, y la transformación la penaliza en consecuencia.

4. Visualización PCA

Una vez transformado el conjunto de datos a las técnicas descritas, podemos explorar la estructura de los datos mediante una reducción de dimensionalidad. Para esto se proyecta el conjunto de entrenamiento sobre las dos primeras componentes principales de los vectores TF-IDF, para observar hasta qué punto los medios resultan separables y analizar cómo cambia esa proyección al variar la representación.

Para esto se evaluó el efecto de tres variantes distintas: (a) eliminar las *stop words* del inglés, palabras vacías estándar más **s**, **u**, **say** y **said**; (b) desactivar el IDF quedándonos solo con la frecuencia de término; y (c) incorporar bigramas además de palabras sueltas.

Dado que se está trabajando con una matriz dispersa no es recomendable aplicar PCA directamente, ya que requiere convertir la matriz en una matriz densa de dimensiones demasiado grandes. Por eso, en lugar de PCA, se utiliza la descomposición SVD truncada, que puede operar directamente sobre la matriz dispersa al no necesitar centrar los datos. Salvo por ese centrado, ambas técnicas son equivalentes.




Figura 4: Proyección sobre las dos primeras componentes SVD del conjunto de entrenamiento: TF-IDF base y las tres variantes de la consigna.

En los cuatro casos los medios aparecen fuertemente solapados: ninguna de las representaciones logra separarlos de forma limpia en dos dimensiones. Aun así, las variantes se comportan de manera muy distinta. El TF-IDF base y la versión con *stop words* producen graficos con forma similar, en los que se insinúa cierta organización: **Reuters** y **The New York Times** tienden a ocupar regiones algo diferentes, con **CNBC** repartido entre ambas, aunque con mucho solapamiento. Quitar las *stop words* no cambia demasiado el aspecto del mapa, pero sí reduce la varianza que capturan las primeras componentes (de un 3,9% a un 1,5% en las dos primeras).

El cambio más marcado aparece al desactivar el IDF (`use_idf=False`). En ese caso las dos primeras componentes concentran mucha más varianza (alrededor del 16%), pero esa varianza no separa a los medios: el primer plano principal se ordena a lo largo de un eje dominado por las palabras más frecuentes —comunes a todos los medios—, y las clases quedan aún

más mezcladas. Esto ilustra el rol del IDF: al penalizar los términos ubicuos, evita que la representación quede gobernada por vocabulario genérico y deja lugar a las diferencias entre medios.

Incorporar bigramas (`ngram_range=(1,2)`), por su parte, multiplica el tamaño del vocabulario de unas 82.000 columnas a más de 1,4 millones pero apenas modifica la proyección, que se mantiene muy parecida a la de unigramas.




Figura 5: Varianza explicada acumulada por las primeras diez componentes SVD.

La Figura 5 confirma la poca varianza explicada del primer plano principal, las dos primeras componentes explican menos del 4% de la varianza total y, aun con diez componentes, no se supera el 8%. Por lo tanto no es posible separar a los medios usando solo dos componentes principales, ya que la información que los distingue está repartida en muchas direcciones del espacio.

Las dos primeras componentes, de todos modos, dejan entrever cierta estructura. Para entender si responde a diferencias temáticas, se visualizaron los centros de gravedad de distintas temáticas o posición de palabras relevantes en el plano principal. En la Figura 6 podemos ver cierta de esta estructura: la sección de mercados (*Markets*) se ubica en la franja de negocios que comparten *Reuters* y *CNBC*, mientras que en el extremo opuesto se agrupan las secciones

más editoriales y culturales de **The New York Times** (*opinion, arts, sports*), que arrastran su centro de gravedad hacia abajo.




Figura 6: Centros de gravedad de cada medio y de algunas secciones representativas, sobre las dos primeras componentes SVD del TF-IDF con stop words. En rojo se marcan algunas palabras muy utilizadas de Reuters que caracterizan la zona superior del plano.

Por último, vale destacar qué términos llevan a **Reuters** a la parte superior del plano, donde se separa del resto. En esa zona se observan palabras como *newsroom*, *eikon*, *coverage* y *source*. Dichas palabras que están presentes en casi todos sus artículos y casi en ningún otro medio, son utilizadas por el medio para cerrar artículos.

Entrenamiento y Evaluación de Modelos

1. Multinomial Naive Bayes

A diferencia de la primer parte, donde se trabajó con el TF-IDF base, para entrenar los modelos partimos de una representación que elimina las *stop words* y, además, las **referencias directas a los medios**: su propio nombre, el de su empresa matriz y los dominios web. Esta decisión está motivada por las pistas detectadas en la Tarea 1, y busca evitar que el clasificador aproveche menciones explícitas del propio medio en lugar de aprender de su contenido.

Se entrena entonces un modelo Multinomial Naive Bayes base, el cual define sus parámetros con valores por defecto de la función *MultinomialNB*.

Se obtiene el *accuracy* del modelo y distintas medidas del desempeño en las predicciones para cada uno de los medios de prensa y presentamos la respectiva matriz de confusión.

$$\text{accuracy} = \frac{\text{Cantidad de predicciones correctas}}{\text{Cantidad total de predicciones}}$$




Figura 7: Matriz de confusión del modelo Multinomial Naive Bayes sobre el conjunto de test.

La matriz de difusión presentada en la Figura 7 expone en cada celda la cantidad de artículos predichos como pertenecientes al medio en la correspondiente columna, que pertenecen en la realidad al medio correspondiente a su fila. Además, se muestra a qué porcentaje de artículos dentro del medio real corresponde esa cantidad.

Tabla 3: Precision, recall y F1 por medio (Multinomial Naive Bayes).

	Precision	Recall	F1-score
CNBC	1.000	0.021	0.041
Reuters	0.697	0.995	0.820
The New York Times	0.937	0.458	0.615

La métricas presentadas en la Tabla 3 se relacionan directamente con la matriz de confusión:

- El *recall* de cada medio se lee por filas, ya que mide qué proporción de los artículos reales de ese medio fue correctamente clasificada.
- La *precision*, en cambio, se interpreta por columnas, porque mide qué proporción de los artículos predichos como un medio realmente pertenecía a ese medio.
- El *F1-score* resume ambas dimensiones mediante un promedio armónico, por lo que penaliza los casos en los que una de las dos métricas es alta pero la otra es muy baja.

La Figura 7 muestra que el modelo tiende a sobre-predecir **Reuters**. Esto se traduce en un *recall* muy alto para ese medio (0.995: acierta 2769 de sus 2782 artículos), pero en una *precision* más baja (0.697), porque **Reuters** absorbe buena parte de los errores del resto: 744 artículos de **CNBC** y 457 de **The New York Times** terminan clasificados como **Reuters**. El caso más extremo es **CNBC**, del que el modelo solo acierta 16 de 773 artículos (*recall* de apenas 0.021); su *precision* es 1, pero el valor engaña, porque casi nunca predice esta clase, y de ahí que su *F1-score* sea muy bajo (0.041). **The New York Times** queda en una situación intermedia: un *recall* de 0.458 (386 de 843 artículos) y una *precision* alta de 0.937, con un *F1-score* de 0.615.

Esto muestra por qué mirar solo el *accuracy* puede ser engañoso. El modelo alcanza un *accuracy* de 0.721, que a primera vista parece aceptable, pero está dominado por la clase mayoritaria: **Reuters** concentra cerca de dos tercios de los artículos, de modo que un clasificador trivial que siempre predijera **Reuters** obtendría un valor similar sin reconocer a los demás medios. Con un desbalance aún mayor el problema se agravaría. Por eso, en problemas con clases desbalanceadas conviene complementar el *accuracy* con la matriz de confusión y con métricas por clase como *precision*, *recall* y *F1-score*.

2. Validación cruzada y búsqueda de hiperparámetros

La validación cruzada permite estimar el desempeño de forma más robusta que con una única partición de validación: el conjunto de entrenamiento se divide en varios pliegues (*folds*) y, en cada iteración, se entrena con todos menos uno y se valida con el restante, promediando luego los resultados. Así se reduce la dependencia de una partición particular. Usamos 5 pliegues, con los datos mezclados previamente. El hiperparámetro a ajustar es *alpha*, que controla la intensidad del suavizado del Multinomial Naive Bayes y evita que un término ausente en

una clase reciba probabilidad nula: valores chicos dejan al modelo más guiado por las frecuencias observadas, mientras que valores grandes suavizan más y vuelven las probabilidades más uniformes.

Se prueba una grilla de 9 valores en escala logarítmica ($[0.001, 0.00316, 0.01, 0.0316, 0.1, 0.316, 1, 3.16, 10]$), apropiada porque el efecto de α varía por órdenes de magnitud. Se excluye el 0, que equivale a no aplicar suavizado y puede generar probabilidades nulas en clasificación de texto. Para cada valor se entrena un modelo y se elige el mejor según su *accuracy* promedio.




Figura 8: Distribución del *accuracy* por valor de α Multinomial Naive Bayes con validación cruzada.

La Figura 8 muestra la distribución del *accuracy* por valor de α : cada punto negro es un pliegue y el rombo blanco, su media.

Tabla 4: Resultados de validación cruzada para distintos valores de α en Multinomial Naive Bayes.

Alpha	Accuracy promedio	Desvío estándar	Ranking
0.0316	0.817	0.008	1
0.1	0.816	0.005	2
0.01	0.811	0.008	3
0.00316	0.809	0.007	4
0.001	0.807	0.008	5
0.316	0.769	0.004	6
1	0.716	0.007	7

El mejor valor según el *accuracy* promedio es $\alpha = 0.0316$ (accuracy de 0.81), aunque 0.1 rinde casi igual y con menor desvío, por lo que también sería una opción razonable; en todos los casos el desvío entre pliegues es moderado. En general, los valores bajos de α funcionan mejor y a partir de 0.1 el *accuracy* cae: un suavizado demasiado fuerte uniformiza las probabilidades de las palabras y le hace perder al modelo la información de las frecuencias observadas. Frente al modelo base ($\alpha = 1$, usado como primera aproximación en la Figura 7), este valor logra alrededor de un 10 % más de aciertos en validación cruzada.

3. Entrenamiento final con el mejor modelo

Con el mejor valor del hiperparámetro ($\alpha = 0.0316$) se reentrena el modelo final sobre todo el conjunto de entrenamiento y se evalúa sobre el conjunto de test, que no se usó durante el ajuste, para obtener una estimación realista de su desempeño sobre datos no observados.




Figura 9: Matriz de confusión normalizada por medio real para el modelo final Multinomial Naive Bayes.

El modelo final alcanza un *accuracy* en test cercano a 0.82 y, como muestra la Figura 9, mejora notablemente la clasificación de **CNBC** y **The New York Times** respecto del modelo base. **Reuters** sigue siendo el medio mejor clasificado, aunque ahora concentra menos predicciones. **CNBC** continúa siendo el más difícil: gran parte de sus artículos se predicen como **Reuters**, algo atribuible tanto a su menor cantidad de artículos como a que comparte características léxicas con **Reuters** en la representación TF-IDF.

Tabla 5: Precision, recall y F1 por medio para el modelo final Multinomial Naive Bayes.

	Precision	Recall	F1-score
CNBC	0.699	0.511	0.590
Reuters	0.871	0.897	0.884
The New York Times	0.738	0.847	0.789

La Tabla 5 confirma esta lectura por clase. **Reuters** obtiene los mejores valores (*precision* 0.871, *recall* 0.897, *F1* 0.884), aunque todavía recibe 285 artículos de **CNBC** mal clasificados. **The New York Times** logra un *recall* alto (0.847; 714 de 843 artículos) con una *precision* algo menor (0.738), para un *F1* de 0.789. **CNBC**, en cambio, sigue siendo el más débil: recupera solo el 51.1% de sus artículos (395 de 773), con una *precision* de 0.699 y un *F1* de 0.590, aunque mejora con claridad respecto del modelo base.

En conjunto, el ajuste de *alpha* mejora el desempeño general y, sobre todo, la recuperación de las clases minoritarias, aunque persiste una confusión relevante entre **CNBC** y **Reuters**, que resultan las más difíciles de separar con este modelo.

Esa confusión persistente se relaciona, en parte, con las limitaciones de representar el texto mediante *bag of words* o TF-IDF. Al modelar cada artículo como una bolsa de términos, estas técnicas ignoran el orden de las palabras y el contexto: dos frases de sentido distinto pueden quedar con representaciones casi idénticas, y se pierden negaciones, relaciones sintácticas o dependencias de largo alcance. Además, al basarse en coincidencias superficiales de vocabulario, tienden a dar peso a marcas de estilo, formato o edición —firmas, fórmulas periodísticas, nombres recurrentes— más que a diferencias temáticas profundas; algo especialmente relevante aquí, donde los medios se distinguen tanto por sus temas como por sus convenciones de redacción, como se vio con las plantillas de **Reuters**.

A esto se suma que ambas representaciones generan matrices de muy alta dimensión y dispersas, lo que vuelve al modelo sensible a términos raros, errores de limpieza o variantes morfológicas; y aunque TF-IDF atenúa el peso de las palabras más comunes, no captura el significado de los términos ni la similitud entre palabras relacionadas. Por eso conviene leer estos resultados como la capacidad del modelo para explotar patrones léxicos, y no como una comprensión real del contenido. Técnicas más avanzadas, como *embeddings* o modelos basados en *transformers*, capturarían relaciones semánticas y contextuales más ricas, a costa de mayor complejidad computacional y menor interpretabilidad.

4. Modelo alternativo: regresión logística multinomial

Como modelo alternativo al Multinomial Naive Bayes se entrena una **regresión logística multinomial**, utilizando exactamente las mismas *features* TF-IDF —sin *stop words* ni referencias directas a los medios— de modo que la comparación entre ambos métodos sea justa.

Ambos son clasificadores lineales y probabilísticos, pero parten de enfoques opuestos. El Multinomial Naive Bayes estima cómo se generan las palabras dentro de cada medio y, asumiendo que dada la clase las palabras son independientes entre sí, aplica el teorema de Bayes para obtener la probabilidad de cada medio. La regresión logística, en cambio, modela directamente la probabilidad de cada medio dado el texto, sin postular un mecanismo de generación de las palabras. Para ello asigna a cada palabra un coeficiente por medio, combina linealmente esos coeficientes con los valores TF-IDF del artículo y transforma el resultado en probabilidades mediante la función *softmax*, que reparte la probabilidad entre los tres medios de forma que sumen uno; el medio con mayor probabilidad es el predicho. Al no asumir independencia entre palabras, la regresión logística puede repartir el peso entre términos que tienden a aparecer juntos, en lugar de tratarlos como evidencia separada como sí lo hace Naive Bayes.

Un aspecto central en este problema es la **cantidad de variables**: aun tras quitar las *stop words* y las referencias a los medios, el vocabulario supera las 80.000 palabras, muchas más que

los 10.262 artículos de entrenamiento. En este caso, con muchas más variables que observaciones, la regresión logística puede presentar problemas para la estimación de los parámetros. Para evitarlo se incorpora un término de **regularización** que penaliza los coeficientes grandes y mantiene el modelo más simple. La implementación de scikit-learn aplica por defecto una penalización **L2 (Ridge)**, controlada por el hiperparámetro C (el inverso de la fuerza de regularización): valores chicos de C penalizan con más fuerza y encogen los coeficientes, mientras que valores grandes dejan al modelo más libre. En este ajuste se utiliza el valor por defecto, $C = 1$, junto con la penalización L2.




Figura 10: Matriz de confusión de la regresión logística multinomial sobre el conjunto de test.

Tabla 6: Precision, recall y F1 por medio (regresión logística multinomial).

	Precision	Recall	F1-score
Medio			
CNBC	0.859	0.520	0.648
Reuters	0.850	0.977	0.909
The New York Times	0.943	0.820	0.877

Una ventaja de la regresión logística frente al Naive Bayes es que sus coeficientes son fácilmente interpretables. Los coeficiente asociado a cada palabra indica cuánto empuja su presencia la predicción hacia ese medio. En la Figura 11 se muestran, para cada medio, las palabras con mayor coeficiente positivo, es decir, las más relevantes a la hora de clasificar.




Figura 11: Palabras con mayor coeficiente positivo para cada medio en la regresión logística multinomial.

Lo que más llama la atención es que, **aun habiendo quitado los stop words y los nombres de los medios**, casi ninguna de las palabras más influyentes es temática: el modelo se apoya sobre todo en marcas de estilo y de formato. **Reuters** se reconoce por el formato de sus cables (*editing*, *reporting*, *text*, *source*, *writing*, *newsroom*) y por rastros de su estructura interna (*corp*, *bengaluru*, sede de una de sus redacciones). **The New York Times** se identifica por sus honoríficos característicos (*mr*, *ms*, *dr*) y por vocabulario editorial (*article*, *editor*, *newsletter*). **CNBC**, en cambio, aparece asociado a contracciones del inglés informal (*don*, *ve*, *ll*, *didn*, fragmentos de “don’t”, “I’ve”, etc.) y a algunos nombres y temas propios (*ceo*, *trump*, *china*, *cramer*, conductor del canal).

Por último, la Figura 12 muestra, sobre un vocabulario reducido a 400 términos para agilizar el cálculo, cómo cambian los coeficientes de algunas palabras al variar la **regularización L2** (*Ridge*) que usa el modelo, es decir, al mover el parámetro C .




Figura 12: Trayectoria de los coeficientes de algunas palabras al variar la regularización L2 (Ridge), sobre un vocabulario reducido.

Las palabras seguidas no son casuales: son las mismas que ya habían aparecido con los coeficientes más altos en la Figura 11 —*editing* y *reporting* para **Reuters**, *mr* y *ms* para **The New York Times**, *trump* y *china* para **CNBC**—. Con regularización fuerte (a la izquierda, con C pequeño) todos los coeficientes se encogen hacia cero, pero al aflojarla (hacia la derecha, con C grande) son justamente esas palabras las que más ganan peso.

Comparación con el Multinomial Naive Bayes

Para cerrar, se comparan directamente los dos clasificadores entrenados sobre las mismas *features* TF-IDF: el modelo final Multinomial Naive Bayes (Sección 3, con $\alpha = 0.0316$) y la regresión logística multinomial recién ajustada. El Cuadro 7 resume su desempeño sobre el conjunto de test.

Tabla 7: Comparación entre el modelo final Multinomial Naive Bayes y la regresión logística multinomial sobre el conjunto de test.

Modelo	Accuracy	F1 CNBC	F1 Reuters	F1 NYT	F1 macro
Multinomial Naive Bayes	0.820	0.590	0.884	0.789	0.754
Regresión logística	0.867	0.648	0.909	0.877	0.811

La regresión logística supera al Multinomial Naive Bayes en *accuracy* (0.87 frente a 0.82) y, sobre todo, en el F1 promedio entre clases (0.81 frente a 0.76), que es la métrica más informativa dado el desbalance. La mejora alcanza a los tres medios: el F1 sube en **CNBC** (de 0.59 a 0.65), en **Reuters** (de 0.88 a 0.91) y en **The New York Times** (de 0.79 a 0.88).

El cambio más claro aparece en la *precision* de las clases minoritarias. Mientras Naive Bayes tendía a sobre-asignar artículos a **Reuters**, la regresión logística es bastante más selectiva al predecir los otros medios: la *precision* de **CNBC** pasa de 0.70 a 0.86 y la de **The New York Times** de 0.74 a 0.94 (Tablas 5 y 6). Esto es coherente con su naturaleza discriminativa: al no asumir independencia entre palabras, modela mejor el solapamiento de vocabulario entre medios y comete menos confusiones hacia la clase mayoritaria.

Aun así, el patrón de fondo se mantiene: **CNBC** sigue siendo la clase más difícil para ambos modelos, con un *recall* en torno a 0.51, lo que confirma que buena parte de sus artículos comparten rasgos léxicos con **Reuters** y resultan difíciles de separar con representaciones TF-IDF, más allá del clasificador elegido. Esta confusión, de hecho, ya estaba anticipada por el análisis exploratorio: en el análisis de correspondencias (Figura 2) **Reuters** y **CNBC** aparecían contiguos y ligados al mismo vocabulario económico e internacional, y en la proyección SVD (Figura 6) ambos compartían la franja de negocios del plano, en torno a la sección de mercados. Las matrices de confusión confirman, desde el lado del modelo, esa proximidad que ya era visible en los datos. En conjunto, la regresión logística ofrece un mejor desempeño global y un mejor equilibrio entre clases, a cambio de un mayor costo de entrenamiento y de la necesidad de regularizar para controlar la enorme cantidad de variables.

5. Cambio de medio de prensa

Para estudiar el efecto del desbalance de clases en un caso extremo, repetimos la clasificación reemplazando a **CNBC** por **Fox News**, un medio que en la base cuenta con apenas 227 artículos. El nuevo conjunto queda formado por **Reuters** (9.272 artículos), **The New York Times** (2.810) y **Fox News** (227), de modo que este último representa menos del 2% del total. Se entrena la regresión logística —el mejor modelo de la sección anterior— con las mismas *features* TF-IDF y partición estratificada.




Figura 13: Matriz de confusión (normalizada por medio real) de la regresión logística sobre el conjunto con Fox News como clase minoritaria.

A primera vista el modelo parece excelente, con un *accuracy* de 0.95, pero ese valor está completamente dominado por **Reuters**: un clasificador que predijera siempre **Reuters** ya obtendría 0.75. La matriz de confusión revela el verdadero problema. De los 68 artículos de **Fox News** en el test, el modelo reconoce solo 24 (un *recall* de 0.35) y manda 33 a **Reuters**; su *precision* es 1.0 cuando se anima a predecir **Fox News** acierta, pero casi nunca elige esa clase. La métrica más honesta es la *macro-F1* (0.80), que promedia las clases sin ponderar por su tamaño y por eso refleja el mal desempeño en la clase minoritaria. Ante la duda, el modelo se inclina por la clase mayoritaria, que es la que minimiza el error global.

Conviene aclarar que la partición estratificada solo garantiza que la proporción de cada clase sea la misma en train y test, pero no corrige el desbalance en sí. Para atacarlo existen dos familias de técnicas de remuestreo. El **submuestreo** (*undersampling*) descarta artículos de la clase mayoritaria hasta equilibrar las clases, con el costo de tirar información potencialmente útil. El **sobremuestreo** (*oversampling*) hace lo contrario: replica o genera sintéticamente ejemplos de la clase minoritaria, con el riesgo de sobreajustar a unos pocos textos repetidos.

6. Técnica alternativa de extracción de features

Una de las limitaciones de *bag of words* y TF-IDF que ya señalamos es que representan cada palabra de forma aislada y dispersa: dos términos relacionados por ejemplo, sinónimos ocupan dimensiones distintas y el modelo no tiene forma de saber que significan algo parecido. Una alternativa que ataca este problema son los **word embeddings**, que representan cada palabra mediante un vector **denso** y de baja dimensión aprendido a partir del contexto en que la

palabra suele aparecer. La idea, conocida como *hipótesis distribucional*, es que las palabras que aparecen en contextos similares reciben vectores similares; así, los términos relacionados quedan próximos en el espacio y la representación captura cierta noción de significado y de sinonimia. Métodos clásicos para obtenerlos son *Word2Vec*.

En cuanto a los resultados, sería esperable que un clasificador basado en *embeddings* dependa menos de la coincidencia exacta de palabras y más del contenido: podría reconocer como parecidos dos artículos que tratan el mismo tema aunque usen vocabulario distinto, algo que TF-IDF no logra. Para clasificar un artículo completo habría que combinar los vectores de sus palabras (por ejemplo, promediándolos) en un único vector de documento. Un paso más allá están los *embeddings contextuales* de los modelos basados en *transformers*, donde la representación de una palabra cambia según la oración, capturando también el orden y el contexto que *bag of words* descarta. A cambio de esa mayor riqueza, estas técnicas son más costosas y bastante menos interpretables que los coeficientes por palabra que pudimos analizar en este trabajo.