

Entrega 2 - Introducción a la Ciencia de Datos

Grupo 8: Facundo Morini, Cecilia Waksman

En este trabajo se busca construir un modelo de clasificación de texto capaz de predecir a qué medio de prensa pertenece un artículo periodístico a partir únicamente de su contenido textual. Para esto se utiliza un subconjunto del dataset *All the News 2.1 – Component One*, que reúne artículos de distintos medios junto con los metadatos asociados a cada publicación.

El análisis exploratorio que se realizó previamente sobre estos mismos datos ya había dejado algunas señales útiles para esta etapa. La primera es el fuerte desbalance en la cantidad de artículos entre medios (Figura 1): **Reuters** concentra una porción muy superior al resto, algo que conviene tener presente tanto al entrenar los modelos como, sobre todo, al interpretar sus métricas. La segunda es que los propios artículos suelen incluir pistas directas de su origen, como menciones al nombre del medio, direcciones web o firmas editoriales, que de no removerse podrían facilitar la tarea de forma artificial. La tercera es que, aunque los medios comparten temáticas transversales como la política estadounidense, mostraban perfiles de vocabulario diferenciados. Esto último quedaba resumido en el análisis de correspondencias entre medios y términos frecuentes (Figura 2): **Reuters** y **CNBC** aparecían próximos entre sí y ligados a un lenguaje económico e internacional, mientras que **The New York Times** se inclinaba hacia la política y hacia temas más cercanos a la vida cotidiana y la cultura. Estas diferencias sugieren, ya de entrada, que habrá medios más fáciles de distinguir que otros.




Figura 1: Diez medios con mayor cantidad de artículos en la base.




Figura 2: Análisis de correspondencias entre los cinco medios principales y las palabras más frecuentes.

Para esta tarea primero se traducirá el texto a una representación numérica con la que un modelo pueda operar, explorando técnicas como *bag of words* y *TF-IDF*, y observando mediante una reducción de dimensionalidad hasta qué punto los medios resultan separables. Luego se entrena y evalúa el rendimiento de modelos como *Multinomial Naive Bayes*, midiendo su desempeño con métricas de clasificación.

Dataset y representación numérica de texto

1. Preparación de los datos

Para esta tarea el análisis se restringe a los tres medios con mayor cantidad de artículos de la base, ya identificados: **Reuters**, **The New York Times** y **CNBC** (Figura 1). Una vez descartados los artículos sin cuerpo de texto, estos tres medios reúnen 14.660 artículos, sobre los que se construye el conjunto de trabajo.

Sobre el cuerpo de cada artículo (variable **article**) se aplica una misma función, de modo de homogeneizar el texto antes de convertirlo en una representación numérica. Esta función elimina el encabezado que precede al primer salto de línea, convierte el texto a minúsculas, reemplaza los signos de puntuación y los saltos de línea por espacios, descarta las palabras que contienen caracteres no alfabéticos (restos de enlaces, números o códigos) y, finalmente, colapsa los espacios múltiples en uno solo.

A partir de este conjunto se separa un 30 % de los artículos para conformar el conjunto de test, reservando el 70 % restante para el entrenamiento. Dado el fuerte desbalance entre medios: **Reuters** concentra cerca del 63 % de los artículos, frente a un 19 % de **The New York Times** y un 18 % de **CNBC**, la partición se realiza mediante **muestreo estratificado**. De esta forma se garantiza que cada medio conserve aproximadamente la misma proporción en ambos subconjuntos, evitando que, por azar, alguno de los medios minoritarios quede sub o sobre-representado en el conjunto de test. Como resultado, el conjunto de entrenamiento queda conformado por 10.262 artículos y el de test por 4.398.

Para verificar que la estratificación efectivamente preservó el balance original, en la Figura 3 se compara la proporción de artículos de cada medio en el conjunto total y en los conjuntos de entrenamiento y test.

(0.0, 74.64211005002274)




Figura 3: Proporción de artículos de cada medio en el conjunto total, de entrenamiento y de test.

Las proporciones resultan prácticamente idénticas en los tres conjuntos: las diferencias entre train y test no superan la centésima de punto porcentual para ningún medio. De todas formas, la figura vuelve a dejar en evidencia el marcado desbalance entre clases, con **Reuters** representando casi dos tercios del total. Este desbalance no se corrige, sino que se mantiene de forma deliberada para trabajar sobre los datos tal como se presentan, pero conviene tenerlo presente de cara a la evaluación de los modelos, ya que condiciona la interpretación de métricas como la *accuracy*, según se discutirá posteriormente.

2. Representación Bag of Words

La técnica de *bag of words* (BOW) traduce cada artículo a un vector de conteos de palabras. Concretamente, se construye una matriz en la que cada fila corresponde a un artículo y cada columna a una de las palabras distintas presentes en el conjunto de entrenamiento; el valor de cada celda es la cantidad de veces que esa palabra aparece en ese artículo. El nombre de la técnica refleja que se descarta el orden de las palabras: solo importa cuántas veces aparece cada una, y no su posición ni el contexto en que se encuentra.

Aplicada sobre el conjunto de entrenamiento, esta transformación produce una matriz de dimensiones (10262, 82287): 10.262 artículos por las 82.287 palabras distintas que conforman el vocabulario.

A modo de ejemplo, en el Cuadro 1 se muestran los conteos de seis palabras del primer artículo, para los cinco primeros artículos del conjunto de entrenamiento. Se eligieron columnas con al menos un valor distinto de cero.

Tabla 1: Ejemplo de representación Bag of Words.

los	angeles	reuters	star	wars	actress
4	4	1	4	3	3
0	0	1	0	0	0
0	0	1	0	0	0
0	0	0	0	0	0
0	0	0	0	0	0

El ejemplo ya anticipa una característica central de esta representación: la enorme mayoría de las celdas valen cero. Cada artículo utiliza apenas una pequeña fracción del vocabulario total; en este subconjunto, el promedio de palabras por artículo es de aproximadamente $424 \ll 82287$, muy por debajo del número de columnas. Incluso el artículo más extenso, con $12069 < 82287$ palabras, está lejos de cubrir el vocabulario completo, de modo que la fila que le corresponde sigue estando dominada por ceros. Por este motivo se dice que la matriz es dispersa.

Por último, vale señalar que esta representación es generalizable: en lugar de contar palabras sueltas, puede contarse la frecuencia de cada secuencia de n palabras consecutivas —un **n-grama**, es decir, una secuencia de n elementos contiguos—, en lo que se conoce como *bag of n-grams*. Vista así, BOW no es más que el caso particular con $n = 1$.

3. Representación TF-IDF

La representación *Term Frequency – Inverse Document Frequency* (TF-IDF) aborda una limitación de los conteos absolutos de BOW: dependen del largo del texto, ya que un artículo más extenso tenderá a repetir más veces cada palabra. El primer componente, *Term Frequency* (TF), corrige esto reemplazando el conteo por una frecuencia relativa al largo del texto:

$$TF_{t,p} = \frac{\text{conteo de la palabra } p \text{ en el texto } t}{\text{conteo total de palabras en el texto } t}$$

El segundo componente, *Inverse Document Frequency* (IDF), pondera cada palabra según qué tan extendida está en el conjunto de textos. Se define como el logaritmo del cociente entre la cantidad total de textos y la cantidad de textos que contienen la palabra:

$$IDF_p = \log\left(\frac{\text{cantidad total de textos}}{\text{cantidad de textos que contienen la palabra } p}\right)$$

De esta forma, las palabras que aparecen en muchos textos —y que, por lo tanto, son poco distintivas, como *the*, *and* o *a*— reciben un peso bajo, mientras que las que aparecen en pocos textos, presumiblemente más informativas del contenido, reciben un peso alto.

La representación final se obtiene multiplicando ambos componentes:

$$TF\text{-}IDF_{t,p} = TF_{t,p} \times IDF_p$$

Reutilizando las mismas palabras del ejemplo anterior, el Cuadro 2 muestra ahora su representación TF-IDF.

Tabla 2: Ejemplo de representación TF-IDF.

los	angeles	reuters	star	wars	actress
0.1289	0.1304	0.0108	0.1272	0.1223	0.1248
0.0000	0.0000	0.0251	0.0000	0.0000	0.0000
0.0000	0.0000	0.0096	0.0000	0.0000	0.0000
0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
0.0000	0.0000	0.0000	0.0000	0.0000	0.0000

En el primer artículo, la mayoría de las palabras del ejemplo toman valores parecidos, en torno a 0.12–0.13. La excepción es **reuters**, con un valor mucho menor (0.01), y esto se explica por los dos componentes a la vez. Por un lado, su *TF* es bajo: en ese artículo **reuters** aparece una sola vez, frente a las cuatro apariciones de palabras como **los** o **star**. Por otro, y sobre todo, su *IDF* también es bajo: **reuters** figura en una gran cantidad de artículos, algo ya previamente visto, donde **Reuters** resultó ser el medio con más artículos y el que más se menciona a sí mismo. Al estar tan extendida, la palabra aporta poca información para distinguir un artículo de otro, y la transformación la penaliza en consecuencia.

4. Visualización PCA

Una vez transformado el conjunto de datos a las técnicas descritas, podemos explorar la estructura de los datos mediante una reducción de dimensionalidad. Para esto se proyecta el conjunto de entrenamiento sobre las dos primeras componentes principales de los vectores TF-IDF, para observar hasta qué punto los medios resultan separables y analizar cómo cambia esa proyección al variar la representación.

Para esto se evaluó el efecto de tres variantes distintas: (a) eliminar las *stop words* del inglés, palabras vacías estándar más **s**, **u**, **say** y **said**—; (b) desactivar el IDF quedándonos solo con la frecuencia de término; y (c) incorporar bigramas además de palabras sueltas.

Dado que se está trabajando con una matriz dispersa no es recomendable aplicar PCA directamente, ya que requiere convertir la matriz en una matriz densa de dimensiones demasiado grandes. Por eso, en lugar de PCA, se utiliza la descomposición SVD truncada, que puede

operar directamente sobre la matriz dispersa al no necesitar centrar los datos. Salvo por ese centrado, ambas técnicas son equivalentes.




Figura 4: Proyección sobre las dos primeras componentes SVD del conjunto de entrenamiento: TF-IDF base y las tres variantes de la consigna.

En los cuatro casos los medios aparecen fuertemente solapados: ninguna de las representaciones logra separarlos de forma limpia en dos dimensiones. Aun así, las variantes se comportan de manera muy distinta. El TF-IDF base y la versión con *stop words* producen graficos con forma similar, en los que se insinúa cierta organización: **Reuters** y **The New York Times** tienden a ocupar regiones algo diferentes, con **CNBC** repartido entre ambas, aunque con mucho solapamiento. Quitar las *stop words* no cambia demasiado el aspecto del mapa, pero sí reduce la varianza que capturan las primeras componentes (de un 3,9 % a un 1,5 % en las dos primeras).

El cambio más marcado aparece al desactivar el IDF (`use_idf=False`). En ese caso las dos primeras componentes concentran mucha más varianza (alrededor del 16 %), pero esa varianza

no separa a los medios: el primer plano principal se ordena a lo largo de un eje dominado por las palabras más frecuentes —comunes a todos los medios—, y las clases quedan aún más mezcladas. Esto ilustra el rol del IDF: al penalizar los términos ubicuos, evita que la representación quede gobernada por vocabulario genérico y deja lugar a las diferencias entre medios.

Incorporar bigramas (`ngram_range=(1,2)`), por su parte, multiplica el tamaño del vocabulario de unas 82.000 columnas a más de 1,4 millones pero apenas modifica la proyección, que se mantiene muy parecida a la de unigramas.




Figura 5: Varianza explicada acumulada por las primeras diez componentes SVD.

La Figura 5 confirma la dificultad: en las representaciones con IDF, las dos primeras componentes explican menos del 4 % de la varianza total y, aun con diez componentes, no se supera el 8 %. Por lo tanto no es posible separar a los medios usando solo dos componentes principales, ya que la información que los distingue está repartida en muchas direcciones del espacio.

Las dos primeras componentes, de todos modos, dejan entrever cierta estructura. Para entender si responde a diferencias temáticas, aprovechamos que el propio conjunto de datos ya trae un área temática etiquetada en la variable `section`. En el Cuadro 3 se listan las cinco secciones más frecuentes de cada medio, que reflejan con bastante claridad su perfil editorial: **Reuters** se

concentra en secciones financieras y de mercados, **The New York Times** reparte su cobertura entre noticias, opinión, cultura y deportes, y **CNBC** mezcla negocios, tecnología y política.

Tabla 3: Cinco secciones más frecuentes en cada medio (porcentaje sobre los artículos con sección registrada).

	Reuters	The New York Times	CNBC
1	World News (13.4 %)	world (11.9 %)	Wires (33.9 %)
2	Market News (12.9 %)	opinion (11.5 %)	Politics (8.3 %)
3	Business News (11.7 %)	us (10.7 %)	Tech (6.9 %)
4	Financials (7.1 %)	arts (8.6 %)	Markets (3.0 %)
5	Intel (5.1 %)	sports (8.5 %)	Market Insider (3.0 %)

En el caso de **CNBC**, la etiqueta más frecuente es *Wires*, que agrupa despachos de agencia y no constituye una temática en sí, por lo que se omite del gráfico que sigue. A partir de ellas tomamos algunas secciones representativas y, sobre el mismo espacio SVD del TF-IDF con stop words, calculamos su centro de gravedad como la posición media de los artículos de entrenamiento que pertenecen a cada sección (Figura 6).




Figura 6: Centros de gravedad de cada medio y de sus secciones más representativas, sobre las dos primeras componentes SVD del TF-IDF con stop words.

La figura confirma la lectura temática. La sección de mercados (*Markets*) se ubica en la franja de negocios que comparten Reuters y CNBC, mientras que en el extremo opuesto se agrupan las secciones más editoriales y culturales de The New York Times (*opinion*, *arts*, *sports*), que arrastran su centro de gravedad hacia abajo.

Parte 2: Entrenamiento y Evaluación de Modelos

1. Multinomial Naive Bayes

Entrene el modelo *Multinomial Naive Bayes* para clasificar los artículos según a qué medio de prensa pertenece el texto. Utilice dicho modelo para clasificar los artículos del conjunto de test, y reporte el valor de *accuracy* y la **matriz de confusión**. Reporte además el valor de *precision* y *recall* para cada medio. Explique cómo se relacionan estos valores con la matriz anterior.

¿Qué problemas puede tener el hecho de mirar solamente el valor de *accuracy*? Considere qué sucedería con esta métrica si el desbalance de datos fuera aún mayor entre medios.

Sugerencia: utilice el método `from_predictions` de `ConfusionMatrixDisplay` para realizar la matriz.

A diferencia de la Parte 1, donde se trabajó con el TF-IDF base, para entrenar los modelos partimos de una representación que elimina las *stop words* y, además, las **referencias directas a los medios**: su propio nombre, el de su empresa matriz y los dominios web. Esta decisión está motivada por las pistas detectadas en la Tarea 1, y busca evitar que el clasificador aproveche menciones explícitas del propio medio en lugar de aprender de su contenido.

```
MultinomialNB()
```

Accuracy en test: 0.721

```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay object at 0x000002011881AD50>
```




Figura 7: Matriz de confusión del modelo Multinomial Naive Bayes sobre el conjunto de test.

Tabla 4: Precision, recall y F1 por medio (Multinomial Naive Bayes).

	precision	recall	f1-score
CNBC	1.000000	0.021000	0.041000
Reuters	0.697000	0.995000	0.820000
The New York Times	0.937000	0.458000	0.615000

3. Entrenamiento final con el mejor modelo

Elija el mejor modelo (mejores parámetros) y vuelva a entrenar sobre todo el conjunto de entrenamiento disponible (sin quitar datos para validación). Reporte el valor final de las métricas y la matriz de confusión. Discuta las limitaciones de utilizar un modelo basado en *bag of words* o TF-IDF para el análisis de texto.

4. Modelo alternativo

Evalúe al menos un modelo más (dentro de scikit-learn) aparte de *Multinomial Naive Bayes* para clasificar el texto utilizando las mismas *features* de texto. Explique brevemente cómo funciona y compare los resultados con el anterior.

```
LogisticRegression(max_iter=1000)
```

```
Accuracy en test: 0.867
```

```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay object at 0x000002010288F560>
```




Figura 8: Matriz de confusión de la regresión logística multinomial sobre el conjunto de test.

Tabla 5: Precision, recall y F1 por medio (regresión logística multinomial).

	precision	recall	f1-score
CNBC	0.859000	0.520000	0.648000
Reuters	0.850000	0.977000	0.909000
The New York Times	0.943000	0.820000	0.877000

Una ventaja de la regresión logística frente al Naive Bayes es que sus coeficientes son fácilmente interpretables. La matriz `logreg.coef_` tiene una fila por medio y una columna por palabra, y el coeficiente asociado a cada palabra indica cuánto empuja su presencia la predicción hacia ese medio. En la Figura 9 se muestran, para cada medio, las palabras con mayor coeficiente positivo, es decir, las más relevantes a la hora de clasificar.




Figura 9: Palabras con mayor coeficiente positivo para cada medio en la regresión logística multinomial.

Lo que más llama la atención es que, **aun habiendo quitado las stop words y los nombres de los medios**, casi ninguna de las palabras más influyentes es temática: el modelo se apoya sobre todo en marcas de estilo y de formato. **Reuters** se reconoce por el formato de sus cables (*editing*, *reporting*, *text*, *source*, *writing*, *newsroom*) y por rastros de su estructura interna (*corp*, *bengaluru*, sede de una de sus redacciones). **The New York Times** se identifica por sus honoríficos característicos (*mr*, *ms*, *dr*) y por vocabulario editorial (*article*, *editor*, *newsletter*). **CNBC**, en cambio, aparece asociado a contracciones del inglés informal (*don*, *ve*, *ll*, *didn*, fragmentos de “don’t”, “I’ve”, etc.) y a algunos nombres y temas propios (*ceo*, *trump*, *china*, *cramer*, conductor del canal).

El resultado es revelador: eliminar las referencias directas al medio no alcanzó para forzar al modelo a fijarse en el contenido. La señal más fuerte sigue viniendo del estilo y el formato (plantillas de redacción, honoríficos, contracciones) e incluso de entidades muy asociadas a cada medio (su sede, sus conductores), además de artefactos de la propia limpieza, como las contracciones partidas al eliminar los apóstrofes. En otras palabras, el clasificador aprende a distinguir *cómo* y *quién* escribe antes que *de qué* se habla. Para medir la verdadera capacidad de diferenciar medios por su temática habría que seguir limpiando estas marcas, y es esperable que la tarea se vuelva entonces bastante más difícil.

Por último, vale la pena ver el rol de la **regularización**, que es lo que controla cuánto peso puede tomar cada palabra. La Figura 10 ilustra, sobre un vocabulario reducido a 400 términos para que el cálculo sea rápido, cómo evolucionan los coeficientes de algunas palabras a medida que se afloja la penalización (es decir, al aumentar C , el inverso de la fuerza de regularización), comparando las penalizaciones L2 (*Ridge*) y L1 (*Lasso*).




Figura 10: Trayectoria de los coeficientes de algunas palabras al variar la regularización, con penalización L2 (Ridge) y L1 (Lasso), sobre un vocabulario reducido.

En ambos casos, cuando la regularización es fuerte (a la izquierda, con C pequeño) todos los coeficientes se encogen hacia cero y el modelo resulta más simple; al aflojarla (hacia la derecha) cada palabra puede pesar más. La diferencia está en *cómo* lo hacen: con **L2 (Ridge)** los coeficientes se reducen de forma suave pero rara vez llegan a cero, mientras que con **L1 (Lasso)** las palabras menos informativas se “apagan”, es decir, su coeficiente pasa a ser exactamente cero (se aprecia, por ejemplo, en *trump* y *china* bajo regularización fuerte), lo que produce un modelo más ralo que selecciona de forma automática las palabras más útiles.

5. Cambio de medio de prensa

Evalúe el problema cambiando al menos un medio de prensa. En particular, observe el (des)balance de datos y los problemas que pueda generar, así como cualquier indicio que pueda ver en el mapeo previo con PCA. Puede ser útil comentar acerca de técnicas como sobre-muestreo y submuestreo; no es necesario implementarlas.

6. Técnica alternativa de extracción de features

Busque información sobre al menos una técnica alternativa de extraer *features* de texto. Explique brevemente cómo funciona y qué tipo de diferencias esperaría en los resultados. No se espera que implemente nada en esta parte.

TODO: Escriba su análisis en el informe.

7. Opcional: Clasificación a nivel de título

Repita la clasificación con los tres medios de prensa originales, pero esta vez clasificando a nivel de **título** en lugar de artículo completo.